

Laporan Awal: Struktur Variabel Data Asuransi Kendaraan

Persiapan Pemodelan Generalized Linear Model (GLM)

1. Pendahuluan

Sebelum melakukan pemodelan *Generalized Linear Model* (GLM), langkah awal yang krusial adalah memastikan validasi struktur dan kesesuaian tipe data[cite: 5]. GLM sangat sensitif terhadap **link function** dan jenis distribusi respons yang digunakan[cite: 5]. Oleh karena itu, variabel harus dikelompokkan dengan benar menjadi variabel kategorikal (faktor) dan variabel kontinu (numerik) agar estimasi parameter model tidak bias.

2. Tabel Deskripsi Variabel

Di bawah ini adalah tabel ringkasan variabel yang digunakan dalam data gabungan asuransi kendaraan periode 2011–2018:

Nama Variabel	Tipe Data R	Deskripsi & Catatan Validasi
SEX	Factor / Category	Jenis kelamin pemegang polis. Harus dikonversi dari numerik (0/1).
INSR_TYPE	Factor / Category	Jenis asuransi kendaraan yang dipilih.
TYPE_VEHICLE	Factor / Category	Kategori atau jenis kendaraan.
MAKE	Factor / Category	Merek atau pabrikan kendaraan.
USAGE	Factor / Category	Tujuan penggunaan kendaraan (misal: pribadi/komersial).
INSURED_VALUE	Continuous / Numeric	Nilai pertanggungan atau harga kendaraan yang diasuransikan.
PREMIUM	Continuous / Numeric	Jumlah premi asuransi yang dibayarkan.
PROD_YEAR	Continuous / Numeric	Tahun produksi kendaraan.
SEATS_NUM	Continuous / Numeric	Jumlah kapasitas tempat duduk kendaraan.
CARRYING_CAPACITY	Continuous / Numeric	Kapasitas muatan kendaraan. Perlu pembersihan khusus karena adanya inkonsistensi string/teks di file tertentu.
CCM_TON	Continuous / Numeric	Kapasitas mesin (CC) atau berat tonase kendaraan. Memiliki korelasi linear kuat dengan TYPE_VEHICLE.

CLAIM_PAID	Continuous / Numeric	Jumlah klaim yang dibayarkan (Variabel respon/dependen).
------------	----------------------	--

3. Catatan Penting untuk Tahap Berikutnya

Inkonsistensi Tipe Data: Kolom CARRYING_CAPACITY terdeteksi terbaca sebagai teks (*string*) pada data 2014–2018 akibat adanya entri kosong atau karakter non-numerik (seperti “-” atau “NA”)[cite: 25, 26, 27]. Kolom ini wajib dibersihkan dan dipastikan bertipe numerik sebelum digabungkan[cite: 25, 30]. **Multikolinieritas:** Variabel CCM_TON memiliki korelasi linear yang kuat dengan TYPE_VEHICLE atau INSURED_VALUE[cite: 10]. Pemeriksaan nilai **VIF (Variance Inflation Factor)** atau **Cramer’s V** wajib dilakukan karena multikolinieritas dapat membuat standard error model GLM membengkak[cite: 11, 12]. **Potensi Overlapping:** Perlu dilakukan pemeriksaan *cleansing* data pada tahun pembatas (2014) untuk memastikan tidak ada data transaksi yang terekspor dua kali agar tidak terjadi *over-counting* pada bobot risiko model[cite: 35, 51, 52].