

GLM_Poisson_NegativeBinomial

Randhy Pratama, Sebastian Adrian Halim, Celline Vercelli, Maria Riwie, Owen Nathanael, Vincensius Ferer C.

18/05/2024

```
library(vcd) # Goodfit
library(dgof) #ks.test
library(fitdistrplus) #MLE
library(ggplot2)
library(dplyr)
library(readxl)
library(EnvStats)
```

Fokus utama pada GLM dengan tipe respons diskrit, adalah memprediksi ekspektasi frekuensi suatu kejadian. Pada collective risk model, ekspektasi frekuensi kejadian ini dinyatakan sebagai $E[N]$.

GLM Diskrit

Untuk kasus GLM dengan tipe respons diskrit, ada dua kemungkinan distribusi keluarga eksponensial yang dapat digunakan yaitu Poisson dan Binomial negative. Kedua distribusi ini memiliki karakteristik yang berbeda jika kita lihat dari rata-rata dan variansinya.

Perhatikan bahwa distribusi Poisson akan memiliki variansi yang sama dengan meannya, karena $V(\mu) = \mu$ dan $\phi = 1$ yang mengakibatkan $Var = \mu$

Sedangkan distribusi Binomial Negatif akan memiliki variansi yang lebih besar dari meannya.

Jadi langkah pertama yang dapat kita lakukan untuk menentukan distribusi apa yang cocok untuk data, adalah dengan melihat nilai mean dan variansi dari respons.

Contoh Data

Berikut adalah data jumlah kematian akibat diabetes yang dipengaruhi oleh faktor usia dan jenis kelamin

```
data=read_excel("diabetes.xls")
data$gender=as.factor(data$gender)
data$age=as.factor(data$age)
head(data)

## # A tibble: 6 x 6
##   gender age  deaths    popn l_popn agemidpt
##   <fct> <fct>   <dbl>   <dbl> <dbl>    <dbl>
```

```
## 1 Male <25      3 1141100 13.9      20
## 2 Male 25-34     0 485571 13.1      30
## 3 Male 35-44    12 504312 13.1      40
## 4 Male 45-54    25 447315 13.0      50
## 5 Male 55-64    61 330902 12.7      60
## 6 Male 65-74   130 226403 12.3      70

str(data)

## tibble [16 x 6] (S3: tbl_df/tbl/data.frame)
## $ gender   : Factor w/ 2 levels "Female","Male": 2 2 2 2 2 2 2 2 1 1 ...
## $ age      : Factor w/ 8 levels "<25","25-34",...: 1 2 3 4 5 6 7 8 1 2 ...
## $ deaths   : num [1:16] 3 0 12 25 61 130 192 102 2 1 ...
## $ popn     : num [1:16] 1141100 485571 504312 447315 330902 ...
## $ l_popn   : num [1:16] 13.9 13.1 13.1 13 12.7 ...
## $ agemidpt: num [1:16] 20 30 40 50 60 70 80 90 20 30 ...

summary(data)

##      gender      age      deaths      popn      l_popn
## Female:8 <25      :2 Min.      : 0.0 Min.      : 29785 Min.      :10.30
## Male :8 25-34      :2 1st Qu.: 3.0 1st Qu.: 214724 1st Qu.:12.27
##      35-44      :2 Median   : 27.5 Median   : 388333 Median   :12.86
##      45-54      :2 Mean      : 60.5 Mean      : 414632 Mean      :12.61
##      55-64      :2 3rd Qu.:109.0 3rd Qu.: 493469 3rd Qu.:13.11
##      65-74      :2 Max.      :192.0 Max.      :1141100 Max.      :13.95
##      (Other):4
##      agemidpt
## Min.      :20.0
## 1st Qu.:37.5
## Median   :55.0
## Mean      :55.0
## 3rd Qu.:72.5
## Max.      :90.0
##
```

Yang menjadi respons adalah death (banyak kematian).

Menentukan Distribusi yang cocok

```
data.frame("Mean"=mean(data$deaths),
           "Variance"=var(data$deaths))

##      Mean Variance
## 1 60.5 4710.933
```

Karena variansi lebih besar daripada mean untuk respons death, maka kecurigaan kita adalah respons ini mengikuti distribusi Binomial Negatif. Untuk memperjelas, maka lakukan uji Chi-Square di bawah ini

- 1) Chi-Square Goodness of Fit

```

# Uji yang digunakan adalah Chi-Square Goodness of Fit

# jika diinginkan menguji terhadap dist neg binom dengan parameter
# tertentu, maka par dapat diisi dengan nilai parameter yang diinginkan

# jika diinginkan distribusi yang diuji adalah poisson,
# maka "nbinomial" cukup diganti dengan "poisson"
summary(goodfit(data$deaths,
                type="nbinomial",
                method=c("MinChisq"),
                par=NULL))

##
## Goodness-of-fit test for nbinomial distribution
##
##           X^2  df  P(> X^2)
## Pearson 187.1384 190 0.5450997

summary(goodfit(data$deaths,
                type="poisson",
                method=c("MinChisq"),
                par=NULL))

##
## Goodness-of-fit test for poisson distribution
##
##           X^2  df  P(> X^2)
## Pearson 6.32006e+41 191      0

```

Berdasarkan uji Chi-Square Goodness of Fit dapat dilihat bahwa 1) p-value yang dihasilkan dari uji Chi-Square Goodness of Fit terhadap distribusi binomial negatif adalah 0.5450997 yang artinya lebih besar dari taraf signifikansi 0.05 sehingga respons death cocok dengan distribusi binomial negatif 2) p-value yang dihasilkan dari uji Chi-Square Goodness of Fit terhadap distribusi poisson adalah 0 yang artinya lebih besar dari taraf signifikansi 0.05 sehingga respons death juga cocok dengan distribusi poisson


Namun, karena dilihat dari variansi data yang lebih besar daripada mean data, maka respons akan lebih cocok dengan distribusi binomial negatif seperti karakteristik dari distribusi binomial negatif itu sendiri. Sedangkan, seperti yang kita tahu bahwa distribusi poisson memiliki karakteristik bahwa mean dan variansi nya sama yang mana kurang cocok dengan nilai mean dan variansi dari respons deaths ini.

Model dengan distribusi binomial negatif memiliki link function yang sama dengan poisson yaitu log. Artinya $\log(\mu)$ yang linier dengan parameter-parameter dan offset pada model. Dalam kasus data ini, terdapat offset yaitu variabel `l_popn`. Offset berfungsi sebagai exposure untuk setiap observasi.

Plot-Plot


Sebelum memulai proses membangun model, akan dibuat beberapa plot dan pengelompokan data untuk melihat perilaku dan hubungan antar variabel.

```
# scatter plot log(deaths) terhadap agemidpt berdasarkan gender  
ggplot(data, aes(x = agemidpt, y = log(deaths))) +  
  geom_point(aes(color = gender)) + ylim(-4,6)
```




Dari plot di atas, dapat ditarik satu kesimpulan penting yaitu hubungan antara log dari deaths dengan agemidpt tidak linier. Kemungkinan besar dapat digunakan model kuadratik atau model kubik untuk merepresentasikan hubungannya.

```
# barplot banyak kematian terhadap kelompok usia, secara umum dan juga dengan pembagian gender  
ggplot(data, aes(x=age,y=deaths)) +  
  geom_col(fill="deepskyblue")
```



```
ggplot(data, aes(x=age,y=deaths)) +  
  geom_col(fill="red") + facet_grid(vars(gender))
```



```
# melihat berapa banyak kematian akibat diabetes berdasarkan gender
data %>% group_by(gender) %>%
  summarise(count = sum(deaths))

## # A tibble: 2 x 2
##   gender count
##   <fct>   <dbl>
## 1 Female   443
## 2 Male    525
```

Menentukan Base Level untuk Age dan Gender

```
# menspesifikasikan base level untuk gender dan kelompok usia
data = data %>% mutate(gender = relevel(gender, ref = "Male"))
data = data %>% mutate(age = relevel(age, ref = "75-84"))
```

Membangun Model

Pada contoh ini, variabel age tidak akan digunakan. Sebagai penggantinya, variabel age midpoint (agemidpt) yang akan digunakan. Pada prakteknya, lebih baik bangun model menggunakan age dan agemidpt kemudian bandingkan kedua model tersebut, mana yang lebih baik.

Kemungkinan model yang dapat dibuat dengan variabel ada dua, yaitu model dengan dan tanpa interaksi. Variabel agemidpt sendiri membuat modelnya dapat ditambahkan dengan polinom. Dari plot log(death) dengan agemidpt, dapat dilihat hubungan yang mungkin adalah kuadratik dan kubik. Berikut beberapa kemungkinan variabel dalam model yang dapat dibuat dengan offset log populasi

Gender+Agemidpt

Gender+Agemidpt+Agemidpt^2

Gender+Agemidpt+Agemidpt^2 +(Agemidpt)^3

Gender+Agemidpt+Agemidpt*Gender

Gender+Agemidpt+Agemidpt^2 +Agemidpt*Gender

Gender+Agemidpt+Agemidpt^2 +Agemidpt^3 +Agemidpt*Gender

```
# seluruh model dengan menggunakan agemidpt berikut interaksi dan hubungan
kuadratik/kubiknya
```

```
model1=glm.nb(
  deaths ~ gender + agemidpt +
  offset(1_popn),data=data,link=log)
summary(model1)
```

```
model2=glm.nb(
  deaths ~ gender + agemidpt +
  I(agemidpt^2) +
  offset(1_popn),data=data,link=log)
```

```
summary(model2)

model3=glm.nb(
  deaths ~ gender + agetidpt +
    I(agemidpt^2) + I(agemidpt^3) +
    offset(l_popn),data=data,link=log)
summary(model3)

model4=glm.nb(
  deaths ~ gender + agetidpt +
    agetidpt*gender +
    offset(l_popn),data=data,link=log)
summary(model4)

model5=glm.nb(
  deaths ~ gender + agetidpt +
    I(agemidpt^2) + I(agemidpt^3) + agetidpt*gender +
    offset(l_popn),data=data,link=log)
summary(model5)

# model yang paling baik, yaitu menggunakan agetidpt,
#memiliki hubungan kuadratik dengan log deaths, dan terdapat interaksi dengan
gender

modelakhir = glm.nb(
  deaths ~ gender + agetidpt +
    I(agemidpt^2) +
    agetidpt*gender +
    offset(l_popn),data=data,link=log)
summary(modelakhir)

##
## Call:
## glm.nb(formula = deaths ~ gender + agetidpt + I(agemidpt^2) +
##       agetidpt * gender + offset(l_popn), data = data, link = log,
##       init.theta = 102849.0374)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.3100  -0.4498  -0.1752   0.6008   1.6251
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -1.630e+01  6.950e-01 -23.446  < 2e-16 ***
## genderFemale    -1.418e+00  4.326e-01  -3.278  0.00104 **
## agetidpt         1.500e-01  2.010e-02   7.460 8.67e-14 ***
## I(agemidpt^2)    -3.499e-04  1.454e-04  -2.407  0.01608 *
## genderFemale:agemidpt  1.157e-02  5.534e-03   2.090  0.03662 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```

##
## (Dispersion parameter for Negative Binomial(102849) family taken to be 1)
##
##      Null deviance: 3304.744  on 15  degrees of freedom
## Residual deviance:   13.371  on 11  degrees of freedom
## AIC: 100.98
##
## Number of Fisher Scoring iterations: 1
##
##
##              Theta: 102849
##            Std. Err.: 785106
## Warning while fitting theta: alternation limit reached
##
## 2 x log-likelihood: -88.981

#Model Akhir dengan Stepwise Regression
modelakhir2=step(glm.nb(
  deaths ~ gender + agemidpt +
    I(agemidpt^2) + I(agemidpt^3) + agemidpt*gender +
    offset(l_popn),data=data,link=log),direction = "both",
  trace = FALSE)
summary(modelakhir)

##
## Call:
## glm.nb(formula = deaths ~ gender + agemidpt + I(agemidpt^2) +
##      agemidpt * gender + offset(l_popn), data = data, link = log,
##      init.theta = 102849.0374)
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -2.3100  -0.4498  -0.1752   0.6008   1.6251
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept)    -1.630e+01  6.950e-01 -23.446  < 2e-16 ***
## genderFemale    -1.418e+00  4.326e-01  -3.278  0.00104 **
## agemidpt         1.500e-01  2.010e-02   7.460 8.67e-14 ***
## I(agemidpt^2)    -3.499e-04  1.454e-04  -2.407  0.01608 *
## genderFemale:agemidpt  1.157e-02  5.534e-03   2.090  0.03662 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(102849) family taken to be 1)
##
##      Null deviance: 3304.744  on 15  degrees of freedom
## Residual deviance:   13.371  on 11  degrees of freedom
## AIC: 100.98
##

```



```
## Number of Fisher Scoring iterations: 1
##
##
##           Theta: 102849
##       Std. Err.: 785106
## Warning while fitting theta: alternation limit reached
##
## 2 x log-likelihood: -88.981
```

Selang Kepercayaan

1) SK Koefisien

```
confint(modelakhir, level=0.95)

## Waiting for profiling to be done...

##              2.5 %      97.5 %
## (Intercept)    -1.773173e+01 -1.500486e+01
## genderFemale   -2.281113e+00 -5.830896e-01
## agemidpt        1.123113e-01  1.911852e-01
## I(agemidpt^2)   -6.458936e-04 -7.557701e-05
## genderFemale:agemidpt 8.677601e-04  2.258704e-02

confint(modelakhir2, level=0.95)

## Waiting for profiling to be done...

##              2.5 %      97.5 %
## (Intercept)    -1.692686e+01 -1.125395e+01
## genderFemale   -2.344845e+00 -6.300797e-01
## agemidpt       -1.177773e-01  1.718721e-01
## I(agemidpt^2)   -6.408680e-04  4.104873e-03
## I(agemidpt^3)   -2.349797e-05  1.420222e-06
## genderFemale:agemidpt 1.517004e-03  2.345508e-02
```

2) SK Mean—disesuaikan dengan link functionnya

```
A=exp(data.frame(predict(modelakhir,
                          newdata = data,
                          interval = 'confidence',
                          level=0.95))) %>% mutate(Deaths= data$deaths)
```

A

	fit	lwr	upr	Deaths
## 1	1.6669458	0.7009854	3.964003	3
## 2	2.6679872	1.4987575	4.749371	0
## 3	9.7178178	6.7561158	13.977851	12
## 4	28.1855527	22.4008312	35.464103	25
## 5	63.5713346	53.9123767	74.960794	61
## 6	123.6511489	108.4916647	140.928860	130
## 7	188.9624785	168.2586498	212.213864	192
## 8	106.5705643	88.1122218	128.895685	102
## 9	0.4843623	0.1662879	1.410847	2

```
## 10 0.9223402 0.4350839 1.955281 1
## 11 3.7356524 2.2507032 6.200328 3
## 12 12.1279729 8.6805398 16.944537 11
## 13 30.1414840 24.0293181 37.808358 30
## 14 71.7701087 61.1236311 84.270983 63
## 15 158.9102879 140.7689329 179.389579 174
## 16 164.9002667 140.0195402 194.202166 159
```

```
B=exp(data.frame(predict(modelakhir2,
                          newdata = data,
                          interval = 'confidence',
                          level=0.95)))) %>% mutate(Deaths= data$deaths)
```

B

```
##          fit          lwr          upr Deaths
## 1 3.0372050 1.2837782 7.185521 3
## 2 3.1284361 2.0014718 4.889958 0
## 3 9.2305618 6.9140145 12.323271 12
## 4 25.4948283 20.4666292 31.758345 25
## 5 60.1213437 51.7728501 69.816051 61
## 6 125.3742470 112.6575511 139.526393 130
## 7 196.7229205 177.3403486 218.223928 192
## 8 101.8914133 86.4731099 120.058827 102
## 9 0.8490901 0.3200069 2.252933 2
## 10 1.0482017 0.5820848 1.887572 1
## 11 3.4642998 2.2881939 5.244911 3
## 12 10.7890400 7.9545414 14.633576 11
## 13 28.2410249 23.1157439 34.502696 30
## 14 72.6242536 63.7090371 82.787034 63
## 15 166.3177953 148.9998649 185.648551 174
## 16 159.6645198 138.9545771 183.461095 159
```

Analysis of Deviance

```
anova(modelakhir, test="Chisq")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model: Negative Binomial(102849), link: log
```

```
##
```

```
## Response: deaths
```

```
##
```

```
## Terms added sequentially (first to last)
```

```
##
```

```
##
```

```
##          Df Deviance Resid. Df Resid. Dev  Pr(>Chi)
## NULL                                15      3304.7
## gender          1         8.0          14      3296.7 0.004563 **
## agemidpt         1      3273.9          13        22.8 < 2.2e-16 ***
## I(agemidpt^2)    1         5.0          12        17.9 0.026088 *
## gender:agemidpt  1         4.5          11        13.4 0.033917 *
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

anova(modelakhir2, test="Chisq")

## Analysis of Deviance Table
##
## Model: Negative Binomial(294922.7), link: log
##
## Response: deaths
##
## Terms added sequentially (first to last)
##
##
##          Df Deviance Resid. Df Resid. Dev  Pr(>Chi)
## NULL                      15     3305.8
## gender           1         8.0         14     3297.8 0.004573 **
## agemidpt          1    3274.9         13         22.8 < 2.2e-16 ***
## I(agemidpt^2)      1         5.0         12         17.9 0.026026 *
## I(agemidpt^3)      1         2.5         11         15.3 0.110741
## gender:agemidpt    1         5.0         10         10.3 0.025077 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

anova(modelakhir, modelakhir2, test="Chisq")

## Likelihood ratio tests of Negative Binomial Models
##
## Response: deaths
##
## Model
## 1          gender + agemidpt + I(agemidpt^2) + agemidpt * gender +
offset(l_popn)
## 2 gender + agemidpt + I(agemidpt^2) + I(agemidpt^3) + agemidpt * gender +
offset(l_popn)
##      theta Resid. df      2 x log-lik.    Test      df LR stat.      Pr(Chi)
## 1 102849.0      11      -88.98141
## 2 294922.7      10      -85.91719 1 vs 2      1 3.064224 0.08003336
```

Pengurangan paling besar terletak pada penambahan variabel agemidpt. Hal ini dapat terlihat dari p-valuenya yang kecil sehingga variabel tersebut sangat signifikan dalam model ini.

Fitting dan Prediksi

Bandingkan hasil prediksi dengan data validation. Jika ada data baru, sintak prediksinya sama, yaitu dengan fungsi predict

```
# prediksi rata-rata banyak kematian akibat diabetes dengan data
#Floor karena kematian harus bulat
```

```

pred=floor(exp(predict(modelakhir,data)))
data.frame(pred,data$deaths)

##      pred data.deaths
## 1      1          3
## 2      2          0
## 3      9         12
## 4     28         25
## 5     63         61
## 6    123        130
## 7    188        192
## 8    106        102
## 9      0          2
## 10     0          1
## 11     3          3
## 12    12         11
## 13    30         30
## 14    71         63
## 15   158        174
## 16   164        159

pred2=floor(exp(predict(modelakhir2,data)))
data.frame(pred,pred2,data$deaths)

```

```

##      pred pred2 data.deaths
## 1      1      3          3
## 2      2      3          0
## 3      9      9         12
## 4     28     25         25
## 5     63     60         61
## 6    123    125        130
## 7    188    196        192
## 8    106    101        102
## 9      0      0          2
## 10     0      1          1
## 11     3      3          3
## 12    12     10         11
## 13    30     28         30
## 14    71     72         63
## 15   158    166        174
## 16   164    159        159

```

Hasil dari Prediksi untuk frekuensi kematian dapat dianalogikan sebagai $E[N]$ pada collective risk model.

```

library(Metrics)

## Warning: package 'Metrics' was built under R version 4.1.3

rmse(data$deaths,pred)

```

```
## [1] 5.373546
```

```
rmse(data$deaths,pred2)
```

```
## [1] 3.66572
```

```
rmsle(data$deaths,pred)
```

```
## [1] 0.4671655
```

```
rmsle(data$deaths,pred2)
```

```
## [1] 0.4494032
```